Sport Data Solution

POC Avantages Sportifs

1 CONTEXTE ET OBJECTIFS

L’entreprise :

Sport Data Solution est une startup de **monitoring sportif**, Elle souhaite **récompenser** ses **161 salariés** sportifs via **deux avantages**.

La mission :

Récompenser les **salariés sportifs** avec des avantages concrets :

- **Prime sportive** *(Trajet domicile–bureau sportif)* : **5 % du salaire brut**.
- **Journées bien-être** *(≥ 15 activités physiques / an)* : **5 jours / an**.

Objectifs du POC

- ✓ **Tester** la **faisabilité technique** de la solution.
- ✓ **Déterminer** les **données à collecter**.
- ✓ **Calculer** l'**impact financier** pour l'entreprise.

2 DONNÉES SOURCES

3 sources de données pour le POC :

Données RH

Données+RH.xlsx

161 salariés — 11 colonnes

- ID salarié
- Nom, Prénom, DDN
- BU (département)
- Date d'embauche
- Salaire brut
- Type de contrat, CP
- Adresse domicile
- Moyen de déplacement

⚠ Données personnelles → RGPD

Données sportives

Données+Sportive.xlsx

161 lignes — 2 colonnes

- ID salarié
- Pratique d'un sport

Nettoyage appliqué :

- Typo « Runing » → Running
- 15 sports distincts

Strava (simulé)

generate_strava.py

2 256 activités — 12 mois

- 95 salariés sportifs
- 15 types de sports
- 5-40 activités / salarié
- Seed reproductible (42)

Colonnes :

- id_salarie, date_debut
- type_sport, distance_m
- duree_s, commentaire

3 ARCHITECTURE TECHNIQUE

Vue d'ensemble du stack :

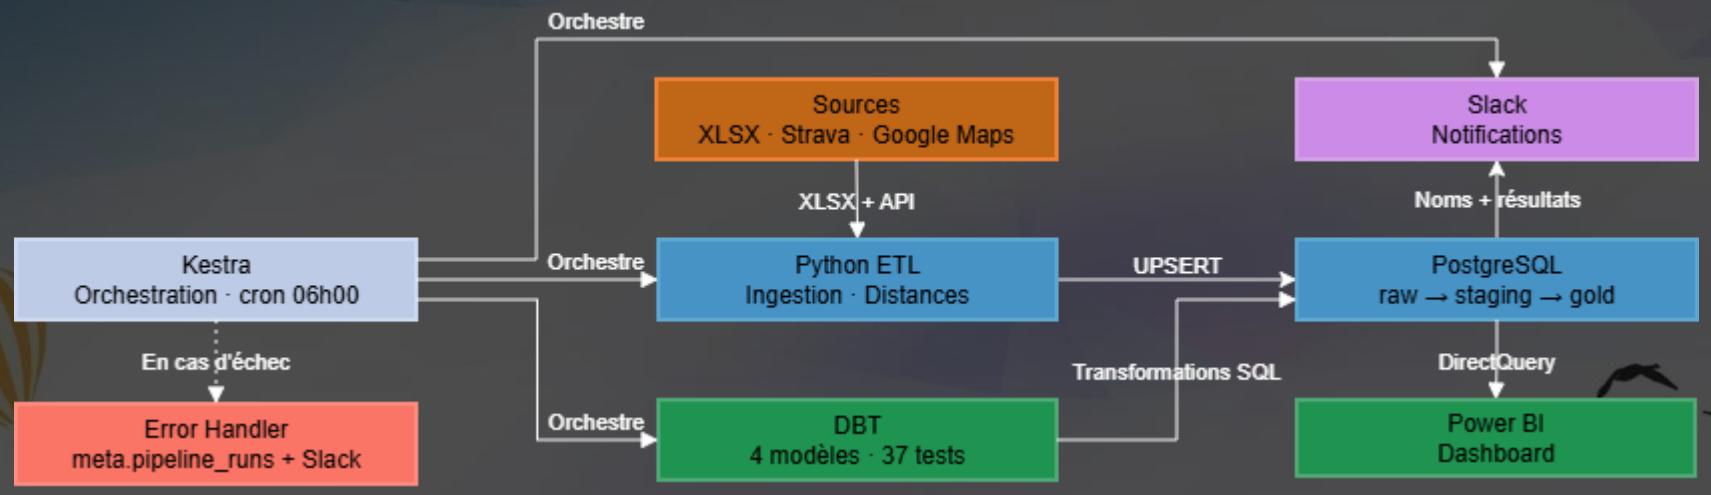

Composant	Outil
Base de données	PostgreSQL 16 (Docker)
ETL / Ingestion	Python 3.12 (pandas, psycopg2)
Transformations SQL	dbt-postgres 1.10
Orchestration	Kestra (UI web, cron, logs)
Distances	Google Maps API + haversine
Tests	pytest (51) + dbt tests (37)
Notifications	Slack Webhooks HTTP
Visualisation	Power BI (DirectQuery)

4 INFRASTRUCTURE DES DONNÉES

Architecture de données Médaillon :

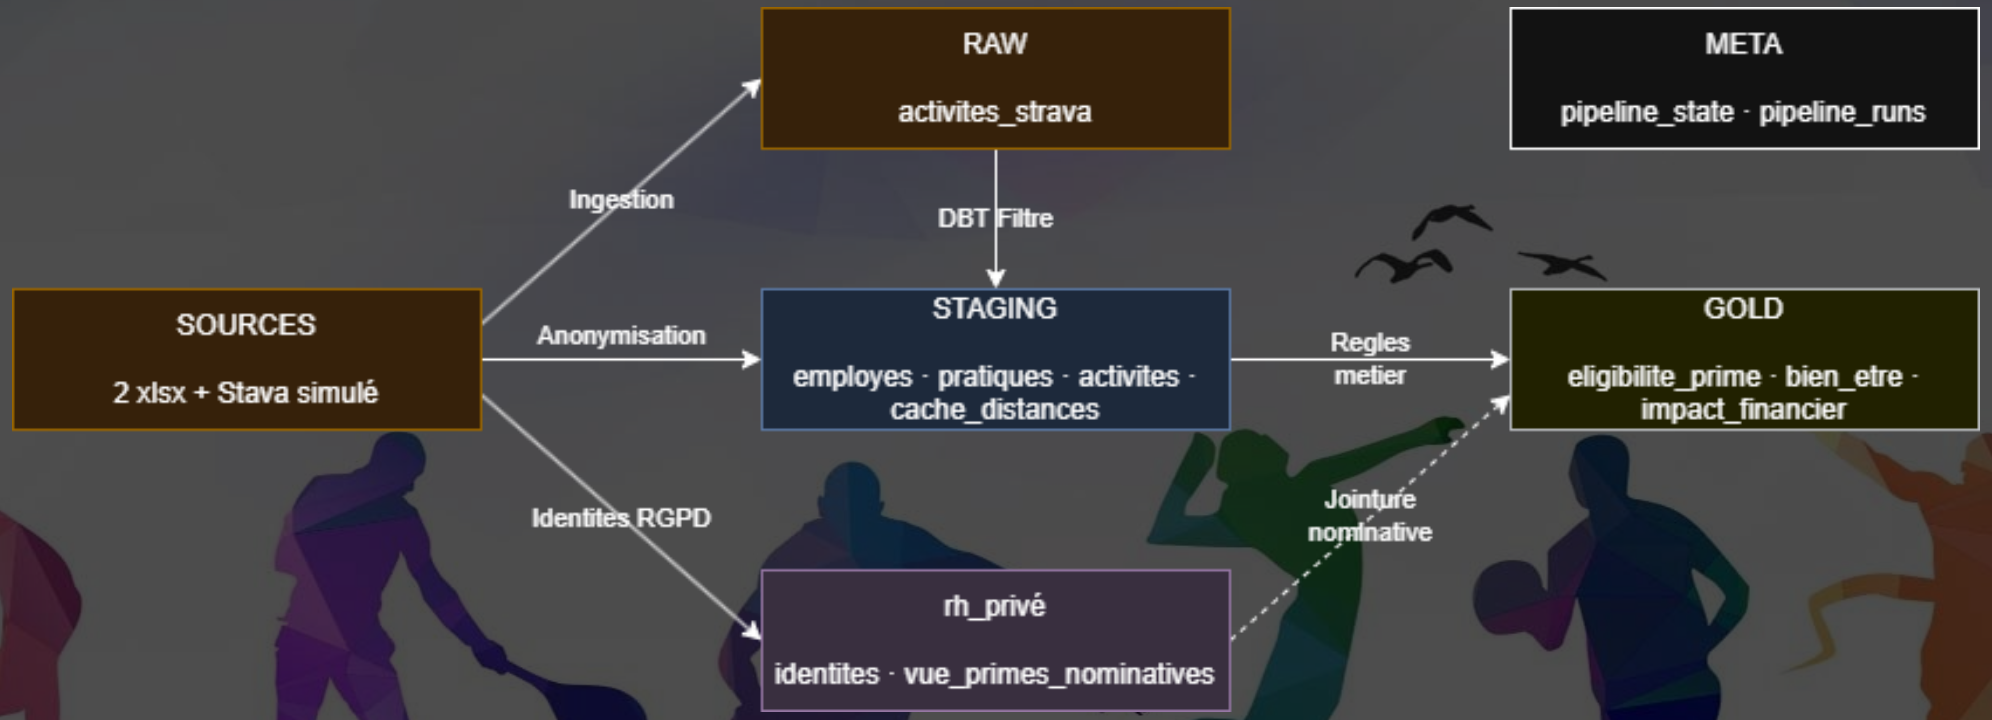

5 PRIVACY BY DESIGN - RGPD

Principe :

Ne stocker que le strict nécessaire, et séparer les données personnelles dès l'ingestion pour que seuls les profils autorisés y accèdent.

Principe du moindre privilège :

Rôle PostgreSQL	Accès	Usage	rh_prive
role_pipeline	raw + staging + gold (R/W)	Pipeline ETL	**Non**
role_analytics	gold (lecture seule)	Power BI	**Non**
role_rh_admin	hérite pipeline + rh_prive	Slack nominatif	**Oui**

6 PIPELINE ETL

6 étapes Python :

init_db.py	→ Crée les schémas, tables et rôles PostgreSQL
load_rh.py	→ Ingère le XLSX RH, anonymise et sépare les identités RGPD
load_sport.py	→ Ingère le XLSX Sportif, nettoi ,et typos
generate_strava.py	→ Simule 2 256 activités Strava (seed=42)
staging.py	→ Crée les schémas, tables et rôles PostgreSQL
gold.py	→ Calcule distances, éligibilités et impact financier

7 TRANSFORMATION DBT

Qu’es ce que DBT :

DBT *(Data Build Tool)* est un **framework** open-source qui permet **d'écrire des transformations de données en SQL** pur, **organisées** en **modèles** avec des **dépendances** *(DAG)*. Chaque modèle est **accompagné** de **tests automatiques** *(unicité, non-null, valeurs acceptées)* et d'une **documentation auto-générée**. DBT exécute les transformations directement dans la base de données *(approche ELT)*, sans déplacer les données.

Dans notre cas :

- **4 modèles SQL** *(staging + gold)*

Modèle	Schéma	Description	Filtres appliqués
stg_activites_strava	staging	Nettoyage raw → staging	distance>0, durée>0, date ≤395j, sport valide, actif=true
eligibilite_prime	gold	Prime 5 % salaire brut	employes × distances × seuils, actif=true
eligibilite_bien_etre	gold	5 jours si ≥15 activités	COUNT activités par salarié actif
impact_financier	gold	Agrégation par département	FULL OUTER JOIN primes × bien-être

- **37 tests dbt**
  - not_null sur toutes les clés et colonnes critiques
  - unique sur les clés primaires (id_salarie)
  - accepted_values sur type_sport (15 sports)
- **Documentation auto** *(Mise à jour auto à chaque exécution du flow)*

8 ORCHESTRATION KESTRA

Qu’es ce que Kestra :

C’est un **orchestrateur** open-source qui **planifie**, **enchaîne** et **surveille** l'exécution de tâches via une interface web, avec **gestion** des **erreurs**, **logs** et déclenchement par **cron**.

Dans notre cas :

Le **flow Kestra** s'exécute **chaque jour** à **06h00** :

- **Détection** : Vérification des xlsx et watermark Strava
- **Ingestion conditionnelle** : Si changement détecté :
  - Met à jour les employés et désactive ceux qui ont quitté l'entreprise
  - Met à jour les sports et supprime ceux des salariés absents
  - Calcule les distances via Google Maps et les stocke en cache
- **Transformations dbt** *(4 model puis tests et doc)*
- **Notifications Slack** *(1 message personnalisé par nouvelle activité Strava)*
- **Finalisation** *(Mise à jour du watermark + INSERT dans meta.pipeline_runs + compte-rendu Slack)*
- **Error handler** *(En cas d'échec à n'importe quelle étape : log en base (status=failed) + notification Slack)*

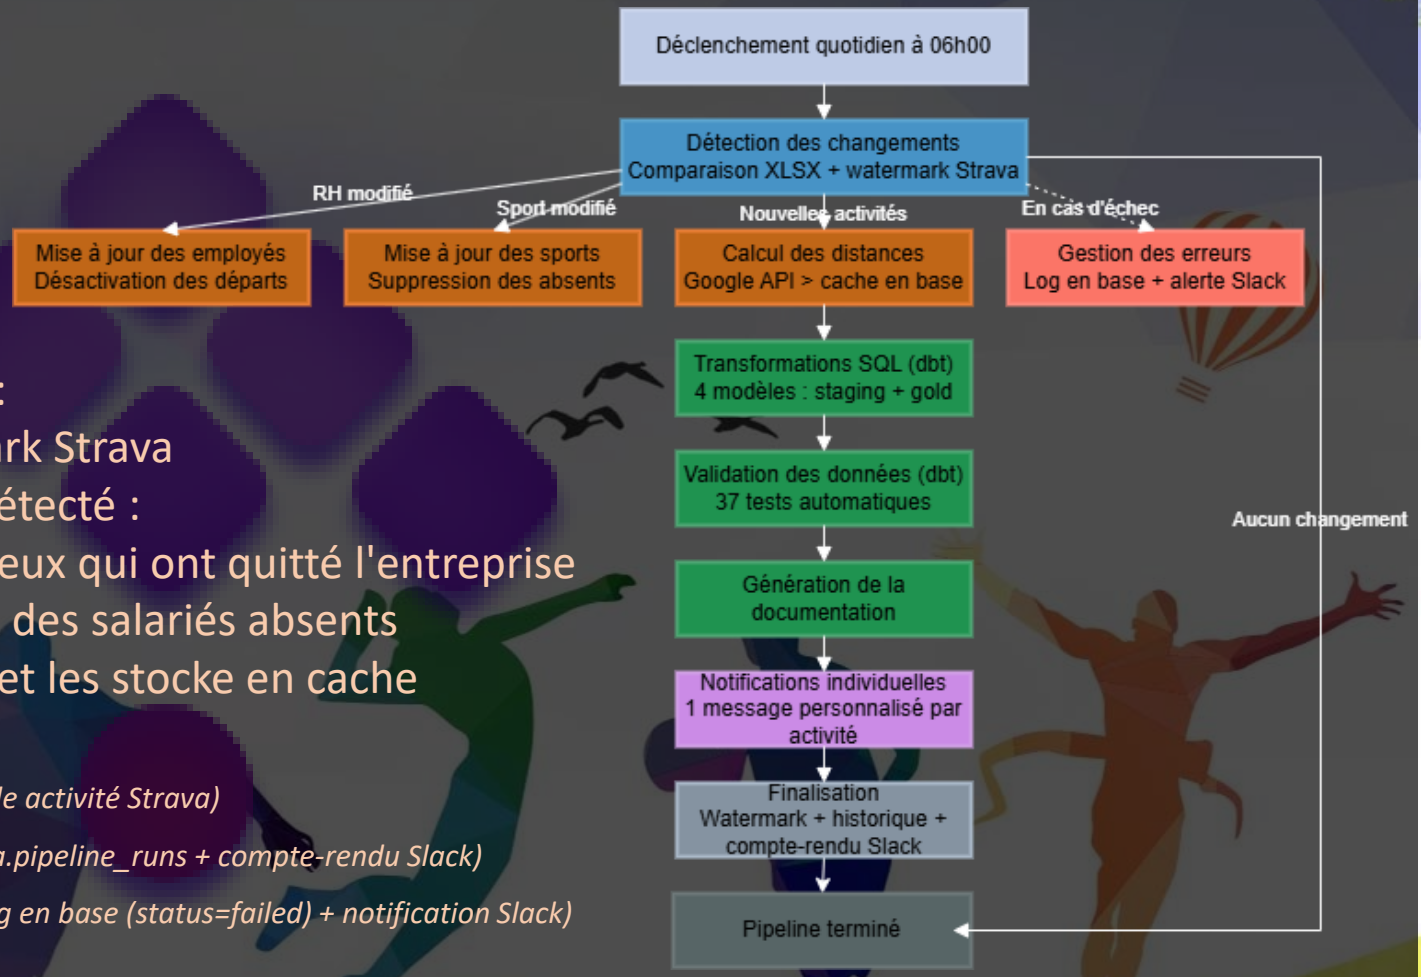

9 TESTS DE QUALITÉ

pytest - 51 tests :

Module	Tests	Couverture
test_distances.py	10	Haversine, seuils, éligibilité, adresse invalide
test_simulation.py	9	Distances, durées, dates, IDs, sports, volumes
test_staging.py	12	Doublons, salaires, dates, complétude, pratiques
test_gold.py	9	Primes 5 %, bien-être ≥15, impact financier
test_rh_prive.py	9	Identités RGPD, FK, Privacy by Design, droits
conftest.py	2	Connexion DB session-scoped + fixture identites

DBT - 37 tests :

- **not_null**
  - Toutes les colonnes critiques
- **unique**
  - Clés primaires *(id_salarie)*
- **accepted_values**
  - type_sport *(15 valeurs)*

51 / 51 PASS
Tests pytest

37 / 37 PASS
Tests dbt

88 / 88 PASS
Tests totaux

10 DASHBOARD : POWERBI

PowerBI :

Le dashboard **Power BI** se connecte directement à **PostgreSQL** en **DirectQuery** *(port 5433, role_analytics)*, ce qui garantit des **données toujours à jour** sans import manuel ni fichier intermédiaire.
Le dashboard est organisé en **deux pages**, séparant les indicateurs **"publics"** des **données RH sensibles**.

P1 - KPIs "publics" *(Vue d'ensemble des activités)*

- Camembert sportifs / non-sportifs (59 % / 41 %)
- Top 10 sports déclarés (histogramme horizontal)
- Top 5 sportifs (classement par nb activités)
- Carte géographique des salariés
- Taux de participation (3 derniers mois)

P2 - KPIs RH *(Impact financier et éligibilités)*

- Histogramme type de mobilité
- Table distances + temps de trajet estimé
- Total jours bien-être gagnés
- Nb salariés éligibles bien-être
- Prime moyenne par salarié éligible
- Total primes sport

Point technique :

La page "**publique**" utilise **role_analytics** *(schéma gold en lecture seule, données anonymes)*.
La page **RH**, qui affiche les noms des salariés, utilise **role_rh_admin**.
Conformément au **principe RGPD** de moindre privilège, **seuls** les **profils RH** habilités accèdent aux données nominatives.

11 CONCLUSION

Ce POC démontre qu'il est possible de construire un pipeline de données complet, de l'ingestion à la restitution, en respectant les contraintes RGPD dès la conception.

Ce qui a été livré :

- ✓ Un **pipeline automatisé** de bout en bout : **ingestion**, **transformation**, **orchestration**, **notification**, **visualisation**
- ✓ Une **architecture Medallion** avec **séparation stricte des données personnelles** *(Privacy by Design)*
- ✓ Une couverture de **tests exhaustive** *(88 tests : 51 pytest + 37 dbt)* garantissant la **fiabilité des résultats**
- ✓ Un **dashboard** Power BI en temps réel pour les décideurs

Ce que le POC a permis de valider :

- ✓ La **faisabilité technique** du calcul des primes sportives et des journées bien-être
- ✓ **L'impact financier** chiffré : **172 482,50 EUR de primes** pour **68 salariés éligibles**
- ✓ La capacité à **orchestrer** l'ensemble avec Kestra **de manière idempotente et traçable**

En un mot : le POC est **opérationnel** et **prêt à évoluer** vers une connexion Strava réelle et un **déploiement cloud**.

The END

Des questions ?